



UNIVERSIDAD DE CONCEPCIÓN
FACULTAD DE INGENIERÍA

**Estimación de Variables Geometalúrgicas con
Machine Learning**

Por
Ignacio Enrique Rojas Rodríguez

Tesina presentada a la Facultad de Ingeniería de la Universidad de Concepción
para optar al grado de Magíster en Ciencia de Datos para la Innovación

Profesor guía: Pedro Pinacho
Profesor co-guía: José Ulloa

Marzo de 2026
Concepción, Chile



Índice

1. Introducción	4
2. Presentación de la propuesta	5
2.1. Problema	5
2.2. Acercamiento, actores, dimensiones	6
2.3. Descripción de la propuesta	6
2.4. Descripción del MVP y objetivos	7
2.5. Descripción de validación	7
3. Obtención de datos	8
4. Depuración de datos	8
5. Exploración de datos	9
6. Modelado de datos	12
7. Interpretación de resultados	19
8. Conclusión	20



Índice de figuras

1.	Distribución original y transformada (Normal Score) de la recuperación en peso.	10
2.	Gráfico Q-Q de la recuperación en peso original y transformada.	10
3.	Distribución espacial 3D de la recuperación en peso.	11
4.	Proyecciones 2D de la recuperación en peso en los planos Este-Norte, Este-Cota y Norte-Cota.	11
5.	Deriva espacial de la recuperación en peso en las direcciones Este, Norte y Cota.	12
6.	Visualización 3D de los clusters definidos por K-Means.	13
7.	Proyecciones 2D de los clusters en los planos Este-Norte, Este-Cota y Norte-Cota.	13
8.	Distribución de recuperación en peso por cluster y efecto proporcional. . . .	14
9.	Recuperación en peso real vs predicha: KNN y Kriging.	15
10.	Recuperación en peso real vs predicha: Gradient Boosting y Kriging.	15
11.	Recuperación en peso real vs predicha: XGBoost y Kriging.	16
12.	Recuperación en peso real vs predicha: Random Forest y Kriging.	16
13.	Comparación de distribuciones de recuperación en peso: datos originales, Kriging y modelos de Machine Learning.	17
14.	Deriva espacial en la dirección Este: comparación entre datos originales, Kriging y modelos de Machine Learning.	18
15.	Deriva espacial en la dirección Norte: comparación entre datos originales, Kriging y modelos de Machine Learning.	18
16.	Deriva espacial en la dirección Cota: comparación entre datos originales, Kriging y modelos de Machine Learning.	19



Índice de tablas

1.	Estadísticos descriptivos de las variables principales.	9
2.	Estadísticos descriptivos de recuperación en peso por cluster (K-Means). . .	12
3.	Métricas de desempeño de los modelos de estimación.	14

1. Introducción

La minería contemporánea se encuentra inmersa en un proceso de transformación digital donde la integración de la información es fundamental para asegurar la viabilidad y rentabilidad de los proyectos a largo plazo [6]. En este contexto, la geometalurgia ha emergido como una disciplina crítica que busca vincular las características geológicas de un yacimiento con su respuesta en los procesos de extracción y beneficio metalúrgico [1]. Sin embargo, la industria enfrenta un obstáculo estructural en la modelación de estas variables: la profunda asimetría en la densidad de los datos. Mientras que la información geológica tradicional suele ser abundante gracias a extensas campañas de sondaje, los datos geometalúrgicos, tales como la recuperación en peso, son comparativamente escasos debido al alto costo y tiempo que demandan los ensayos de laboratorio [4]. La recuperación en peso se define como la razón entre la masa del concentrado obtenido y la masa total del mineral alimentado al proceso, expresada matemáticamente como:

$$R_p(\%) = \left(\frac{Masa_{Conc}}{Masa_{Alim}} \right) \times 100 \quad (1)$$

donde R_p es la recuperación en peso, $Masa_{Conc}$ la masa del concentrado final obtenido del circuito y $Masa_{Alim}$ la masa de alimentación al circuito.

Tradicionalmente, la estimación espacial de estas variables se ha abordado mediante herramientas geoestadísticas clásicas [3]. Si bien estos métodos son robustos en escenarios de alta densidad de muestreo, su aplicación sobre conjuntos de datos reducidos resulta en un proceso lento, iterativo y altamente dependiente del juicio experto para forzar supuestos de estacionariedad [2] o anisotropía [5]. Además, estos flujos de trabajo están fuertemente condicionados por el uso de licencias de software propietario de alto costo, lo que limita la capacidad de las empresas para experimentar y democratizar el análisis de sus propios datos [6].

Frente a esta problemática, la presente tesina, desarrollada en el marco del Magíster en Ciencia de Datos para la Innovación de la Universidad de Concepción, propone incorporar Machine Learning para la estimación de variables geometalúrgicas [6]. El objetivo central es construir un Producto Mínimo Viable (MVP) programado en Python que automatice la estimación espacial de la recuperación en peso a partir de un conjunto reducido de datos [1]. La hipótesis subyacente es que los algoritmos de aprendizaje automático, tanto no supervisados para la definición de dominios como supervisados para la estimación continua, poseen la flexibilidad matemática necesaria para capturar las complejas relaciones espaciales del mineral sin depender de las rígidas restricciones paramétricas de la geoestadística tradicional [1].

Para demostrar la validez de esta propuesta, el documento se estructura siguiendo el ciclo de vida de un proyecto de ciencia de datos aplicado a la minería. En primer lugar, se expone el marco y alcance de la propuesta, definiendo el problema de negocio y los objetivos del MVP. A continuación, se detalla el proceso de obtención, depuración y transformación estadística de la base de datos geometalúrgica. Posteriormente, se presenta un análisis exploratorio

espacial que justifica la elección de las variables predictoras. El núcleo de la investigación se desarrolla en la sección de modelado, donde se implementan técnicas de agrupamiento tridimensional y se contrastan modelos predictivos avanzados contra el modelo de bloques vigente de la empresa. Finalmente, se interpretan los resultados desde una perspectiva técnica y operacional, concluyendo con los hallazgos y el impacto potencial de incorporar este flujo de trabajo en la industria minera.

2. Presentación de la propuesta

La presente propuesta consiste en desarrollar e implementar una alternativa metodológica para la estimación de variables geometalúrgicas, integrando técnicas de ciencia de datos y aprendizaje automático (Machine Learning) al flujo de trabajo tradicional de la industria minera. Mediante la construcción de un Producto Mínimo Viable (MVP) programado íntegramente en Python, se busca comparar los resultados de esta nueva aproximación con las estimaciones convencionales, evaluando la viabilidad de la propuesta en términos de precisión técnica, reducción de tiempos de procesamiento y disminución de la dependencia de software comercial de alto costo.

2.1. Problema

La industria minera enfrenta el desafío constante de integrar información geológica y geometalúrgica para sustentar la planificación de largo plazo. Sin embargo, existe una profunda asimetría en la densidad de la información: mientras los datos geológicos (como litología o alteración) suelen ser abundantes, los datos propiamente geometalúrgicos son comparativamente escasos. Variables críticas como la recuperación en peso requieren ensayos de laboratorio de alto costo, lo que limita su cantidad a unos pocos cientos de registros dentro de un yacimiento. Esta escasez de datos genera una dificultad para la estimación espacial continua.

Los enfoques geoestadísticos tradicionales, como el *Kriging*, fueron desarrollados para operar sobre conjuntos de datos suficientemente densos que permitan un estudio variográfico robusto. Aplicar estas metodologías tradicionales a bases de datos reducidas requiere un trabajo experto intensivo para forzar supuestos de estacionariedad, definir elipses de búsqueda y modelar el comportamiento isotrópico o anisotrópico. Como resultado, las estimaciones pueden volverse inestables o excesivamente suavizadas, disminuyendo la confianza en los modelos utilizados para la toma de decisiones. Una estimación poco representativa de la recuperación geometalúrgica impacta directamente en la proyección de tonelajes, el diseño del proceso y los indicadores económicos del proyecto.

Adicionalmente, estos flujos de trabajo dependen fuertemente de licencias de software especializado de alto costo y de rutinas intensivas en tiempo humano. Frente a este escenario, surge la necesidad de explorar si algoritmos de aprendizaje automático, capaces de encontrar relaciones espaciales complejas y no lineales sin requerir los estrictos supuestos paramétricos de la geoestadística, pueden ofrecer estimaciones de calidad comparable o superior, agilizan-

do el proceso y democratizando el uso de los datos mediante lenguajes de programación de código abierto.

2.2. Acercamiento, actores, dimensiones

La iniciativa surge del interés por incorporar prácticas de ciencia de datos a la estimación de recursos. El acercamiento metodológico se estructura en un flujo de trabajo ágil y reproducible. En lugar de realizar extensos estudios variográficos, se utilizan técnicas de aprendizaje no supervisado para definir dominios con coherencia espacial y metalúrgica, seguidas de modelos supervisados que aprenden de manera autónoma las relaciones espaciales subyacentes de la variable a estimar.

Los actores principales y beneficiarios directos de esta propuesta son los geólogos, geometalurgistas y planificadores mineros responsables de los proyectos de estimación. A nivel corporativo, el proyecto dialoga con la necesidad estratégica de la empresa de optimizar recursos y explorar alternativas tecnológicas eficientes.

La propuesta abarca tres dimensiones clave:

- **Dimensión técnica:** Demostrar empíricamente que algoritmos como K-Means y KNN pueden capturar la continuidad y anisotropía espacial de variables escasas con métricas de error competitivas.
- **Dimensión de negocio:** Proveer una alternativa que reduzca los tiempos de modelamiento experto y evalúe la factibilidad de independizar parte del proceso de las costosas licencias de software propietario.
- **Dimensión de adopción tecnológica:** Entregar un MVP en Python que funcione como código base replicable, fomentando la cultura de *Data Science* dentro de los equipos técnicos de la compañía.

2.3. Descripción de la propuesta

La propuesta se materializa en un flujo de trabajo computacional (pipeline) focalizado en una variable geometalúrgica crítica y escasamente muestreada: la recuperación en peso. A partir de una base de datos de 1.219 registros de laboratorio, el MVP se encarga de procesar, transformar y modelar la información de principio a fin en un entorno Python.

El proceso inicia con una fase de limpieza y transformación de datos, aplicando una transformación gaussiana (*Normal Score Transformation*) para estabilizar la distribución de la variable objetivo. Posteriormente, se aplica un agrupamiento tridimensional automatizado mediante K-Means, que reemplaza la definición manual de dominios metalúrgicos por una segmentación objetiva basada en la posición espacial y la respuesta metalúrgica de los datos. Con los dominios identificados, se entrenan cuatro modelos predictivos sobre el total de los datos disponibles: K-vecinos más cercanos (KNN), Random Forest, Gradient Boosting y XGBoost, utilizando las coordenadas tridimensionales como variables predictoras.

La validación de los modelos se realizó de forma externa, comparando las predicciones de cada modelo contra los valores reales en los puntos del modelo de bloques vigente de la empresa, estimado mediante Kriging. Esto permite medir de forma objetiva el desempeño del Machine Learning frente al método tradicional, bajo exactamente las mismas condiciones y sobre los mismos puntos de referencia.

2.4. Descripción del MVP y objetivos

El producto mínimo viable (MVP) corresponde a un conjunto de *notebooks* y *scripts* en Python que ejecutan secuencialmente la carga de datos, el análisis exploratorio (EDA), el *domaining* no supervisado, el entrenamiento de modelos supervisados y la generación masiva de estimaciones sobre una grilla espacial o "modelo de bloques" sintético, incluyendo sus respectivas métricas de error visuales y numéricas.

Objetivo general: Desarrollar y evaluar un flujo de trabajo basado en aprendizaje automático para la estimación espacial de variables geometalúrgicas con datos escasos, contrastando su rendimiento, agilidad y costo de implementación frente a las metodologías geoestadísticas tradicionales utilizadas por la empresa.

Objetivos específicos:

- Diseñar un flujo automatizado para el preprocesamiento y transformación estadística de datos geometalúrgicos.
- Implementar técnicas de aprendizaje no supervisado para la delimitación matemática de dominios geometalúrgicos espaciales.
- Entrenar y optimizar modelos de aprendizaje supervisado para predecir la recuperación en peso, evaluando su desempeño sobre los puntos de validación del modelo de bloques de la empresa y verificando la coherencia espacial de las estimaciones.
- Comparar el desempeño cuantitativo, la coherencia espacial y el esfuerzo operativo del modelo de *Machine Learning* frente al modelo oficial de la empresa.

2.5. Descripción de validación

Validar un modelo de estimación espacial presenta un desafío inherente a este tipo de problemas: los puntos no muestreados del yacimiento no tienen un valor de referencia conocido. Para abordarlo, la validación de esta tesina se apoya en tres enfoques complementarios.

El primero es una **validación estadística interna**. Los modelos se entrenaron con el 100 % de los datos disponibles, decisión justificada por el volumen reducido de la base de datos, y su comportamiento se evaluó mediante métricas estándar como el coeficiente de determinación (R^2) y la raíz del error cuadrático medio (RMSE). Esto permite medir qué tan bien ajusta el modelo a los datos con los que fue construido.

El segundo es una **validación geoespacial**. Se verificó que las estimaciones masivas preserven la distribución estadística original y que no introduzcan sesgos sistemáticos en ninguna dirección del espacio. Para esto se analizó la deriva espacial (*drift*) en los ejes Este, Norte y Cota, comprobando que el modelo respeta las tendencias macroscópicas del yacimiento.

El tercero, y más relevante para evaluar el desempeño real del MVP, es una **validación externa contra el modelo de la empresa**. La compañía cuenta con un modelo de bloques de aproximadamente 380.000 puntos, estimados mediante Kriging utilizando la misma base de datos de laboratorio que se emplea en este trabajo. Para realizar la comparación, se identificó el punto del modelo de la empresa más cercano a cada una de las muestras originales. La distancia promedio entre pares fue de aproximadamente 7 metros, lo que es suficientemente pequeño para asumir que ambos valores, el real de laboratorio y el estimado por Kriging, deberían ser similares. Bajo esa premisa, el Kriging de la empresa actúa como *benchmark*: se midió primero cuánto explica el Kriging de la variabilidad de los datos reales ($R^2 \approx 80\%$), y luego se comparó ese resultado con el desempeño de los modelos de Machine Learning sobre los mismos puntos.

3. Obtención de datos

Los datos utilizados en esta investigación provienen de dos fuentes distintas. Por acuerdos de confidencialidad, no se detallan los nombres específicos del yacimiento ni las fechas de las campañas de exploración.

La primera fuente corresponde a una base de datos de sondeos y pruebas geometalúrgicas de laboratorio, provista por una empresa minera externa. La información fue entregada en formato tabular, consolidando en una única estructura la ubicación espacial de las muestras y su respuesta metalúrgica. Esta base contiene 1,219 registros finales, donde cada uno incluye las coordenadas espaciales tridimensionales (Este, Norte y Cota), junto con la recuperación en peso (%) como variable objetivo principal. Estos registros constituyen la base sobre la cual se desarrolla el análisis exploratorio, la definición de dominios y el entrenamiento de los modelos predictivos.

La segunda fuente es el modelo de bloques vigente de la empresa consultora donde se desarrolla esta tesina, que contiene 343,732 puntos estimados mediante Kriging. Este modelo fue construido utilizando la misma base de datos de laboratorio, y cubre de forma continua el volumen del yacimiento. Su rol en esta tesina es exclusivamente el de referencia para la validación externa: permite comparar directamente las estimaciones del Machine Learning contra las del método geoestadístico oficial sobre los mismos sectores del yacimiento.

4. Depuración de datos

Antes de comenzar con el análisis, se revisó y limpió la base de datos para asegurar que la información que alimenta los modelos sea consistente y confiable.

El conjunto inicial contaba con 1.466 registros. Durante la revisión se identificaron 230 registros con el valor -99 , que es la convención utilizada en estas bases de datos para indicar que una prueba de laboratorio no tiene resultado. Estos registros fueron eliminados por no aportar información útil para el modelado.

Adicionalmente, se eliminaron 17 registros cuya coordenada Norte superaba los 27.000 metros, ya que corresponden a muestras ubicadas fuera del área de interés del yacimiento y podrían introducir ruido en las estimaciones espaciales.

Tras ambos filtros, la base de datos quedó conformada por 1.219 registros válidos, lo que representa el 83,2% del total original. Este es el conjunto que se utiliza en todas las etapas posteriores del trabajo.

Una vez depurada la base, se analizó la distribución de la variable objetivo. La recuperación en peso presenta una distribución asimétrica, con una cola extendida hacia valores altos, lo que puede afectar el comportamiento de los modelos. Para corregir esto, se aplicó una transformación gaussiana (*Normal Score Transformation*), que ajusta la distribución original hacia una normal estándar con media $\mu = 0$ y desviación estándar $\sigma = 1$. Todas las etapas de modelado se realizaron sobre esta variable transformada.

5. Exploración de datos

Para entender cómo se distribuyen los datos en el espacio, se generaron visualizaciones en tres y dos dimensiones, donde el eje Este corresponde a la dirección X, el Norte a la dirección Y y la Cota a la dirección Z. La Figura 3 muestra que la gran mayoría de las muestras presenta valores de recuperación inferiores al 21 % (tonos azules), mientras que los valores más altos aparecen de forma localizada, lo que sugiere continuidad espacial y no una distribución aleatoria.

La Tabla 1 resume los principales estadísticos descriptivos del conjunto de datos.

Tabla 1: Estadísticos descriptivos de las variables principales.

Variable	N	Promedio	Desv. Est.	Mín.	Máx.
	(1)	(2)	(3)	(4)	(5)
Este (m)	1.219	9.009,09	162,44	8.438,38	9.381,41
Norte (m)	1.219	24.797,32	703,99	23.604,57	26.790,97
Cota (m)	1.219	2.058,27	170,73	1.219,74	2.312,77
Recuperación en peso (%)	1.219	18,00	6,63	4,35	60,87

Nota: Elaboración propia en base a los datos del estudio. (1) = tamaño de muestra, (2) = promedio, (3) = desviación estándar, (4) = mínimo valor observado, (5) = máximo valor observado.

La recuperación en peso tiene una media de 18% y una mediana de 16,6%, lo que ya sugiere una distribución asimétrica hacia la derecha. Esto se confirma en la Figura 1, donde el

histograma original muestra una cola extendida hacia valores altos, con un máximo de 60,87 % que se aleja considerablemente del tercer cuartil. Tras aplicar la transformación gaussiana, la distribución adopta una forma de campana simétrica, lo que se valida adicionalmente en el gráfico Q-Q de la Figura 2, donde los puntos se alinean sobre la diagonal de referencia.




Figura 1: Distribución original y transformada (Normal Score) de la recuperación en peso.




Figura 2: Gráfico Q-Q de la recuperación en peso original y transformada.

Para entender cómo se distribuyen los datos en el espacio, se generaron visualizaciones en tres y dos dimensiones. La Figura 3 muestra que la gran mayoría de las muestras presenta valores de recuperación inferiores al 21 % (tonos azules), mientras que los valores más altos aparecen de forma localizada, lo que sugiere continuidad espacial y no una distribución aleatoria.

Distribución Espacial de la Recuperación en Peso (%)




Figura 3: Distribución espacial 3D de la recuperación en peso.

Las proyecciones en dos dimensiones de la Figura 4 permiten identificar con mayor claridad la concentración de muestras y la ubicación de las zonas de mayor recuperación en cada plano del yacimiento.




Figura 4: Proyecciones 2D de la recuperación en peso en los planos Este-Norte, Este-Cota y Norte-Cota.

Finalmente, se analizó la deriva espacial de la variable en las tres direcciones principales. La Figura 5 muestra que la recuperación en peso no es constante a lo largo del yacimiento: en la dirección Norte se observa una caída progresiva desde valores cercanos a 28 % en el

extremo sur hacia valores de 15% en el norte, mientras que en la dirección Este y Cota las variaciones son más moderadas. Esta tendencia confirma que la posición espacial es una variable predictora relevante para el modelado.




Figura 5: Deriva espacial de la recuperación en peso en las direcciones Este, Norte y Cota.

6. Modelado de datos

El modelado se estructura en dos etapas. Primero, un análisis de agrupamiento no supervisado mediante K-Means, que busca identificar si existen sectores del yacimiento con comportamientos metalúrgicos diferenciados. Segundo, el entrenamiento de modelos supervisados de Machine Learning para estimar la recuperación en peso, cuyos resultados se validan contra el modelo de Kriging de la empresa.

Para explorar si el yacimiento presenta zonas con comportamientos metalúrgicos distintos, se aplicó el algoritmo K-Means utilizando las coordenadas espaciales (Este, Norte y Cota) y la recuperación en peso transformada como variables de entrada. El número de clusters se definió en tres, valor que además coincide con la segmentación que maneja la empresa en su modelo de bloques, lo que facilita la comparación entre ambos enfoques.

La Tabla 2 resume las estadísticas descriptivas de recuperación en peso para cada cluster.

Tabla 2: Estadísticos descriptivos de recuperación en peso por cluster (K-Means).

Cluster	N	Promedio	Desv. Est.	Mín.	Mediana	Máx.
	(1)	(2)	(3)	(4)	(5)	(6)
1	580	18,74	5,97	6,26	17,91	42,97
2	371	19,56	7,94	7,22	17,73	60,87
3	268	14,25	4,12	4,35	13,44	36,24

Nota: Elaboración propia en base a los datos del estudio. (1) = tamaño de muestra, (2) = promedio, (3) = desviación estándar, (4) = mínimo valor observado, (5) = mediana, (6) = máximo valor observado.

Los clusters 1 y 2 presentan recuperaciones promedio similares, cercanas al 19%, aunque el

cluster 2 muestra mayor dispersión y contiene los valores más altos del yacimiento. El cluster 3 se diferencia claramente con una recuperación promedio de 14,25 % y menor variabilidad. La Figura 6 muestra que esta separación también tiene coherencia espacial, con los tres grupos ocupando sectores distintos del yacimiento.

Distribución Espacial de la Recuperación en Peso (%)




Figura 6: Visualización 3D de los clusters definidos por K-Means.




Figura 7: Proyecciones 2D de los clusters en los planos Este-Norte, Este-Cota y Norte-Cota.

La Figura 8 complementa el análisis mostrando la distribución de recuperación por cluster y el efecto proporcional, que refleja la relación entre la media y la dispersión de cada grupo.

El cluster 2 presenta el mayor efecto proporcional, lo que indica que en ese sector los valores altos de recuperación van acompañados de mayor variabilidad.




Figura 8: Distribución de recuperación en peso por cluster y efecto proporcional.

Para la estimación de la recuperación en peso se entrenaron cuatro modelos de Machine Learning: K-Nearest Neighbors (KNN), Random Forest, Gradient Boosting y XGBoost. Todos los modelos se entrenaron con el 100 % de los 1.219 datos disponibles, utilizando las coordenadas espaciales (Este, Norte y Cota) como variables predictoras. La validación se realizó de forma externa, comparando las predicciones de cada modelo contra los valores reales en los 1.219 puntos del emparejamiento descrito en la sección 2.5, usando el Kriging de la empresa como referencia bajo las mismas condiciones.

La Tabla 3 resume las métricas de desempeño de todos los modelos.

Tabla 3: Métricas de desempeño de los modelos de estimación.

Modelo	N	R^2	RMSE	MAPE
	(1)	(2)	(3)	(4)
Kriging (empresa)	1.219	0,796	2,992	10,5 %
KNN	1.219	0,630	4,032	13,3 %
Gradient Boosting	1.219	0,387	5,187	19,6 %
XGBoost	1.219	0,364	5,282	20,0 %
Random Forest	1.219	0,342	5,372	20,3 %

Nota: Elaboración propia en base a los datos del estudio. (1) = tamaño de muestra, (2) = coeficiente de determinación, (3) = raíz del error cuadrático medio, (4) = error porcentual absoluto medio.

El Kriging de la empresa obtiene el mejor desempeño con un R^2 de 0,796 y un MAPE de 10,5 %. Entre los modelos de Machine Learning, KNN es el que mejor resultado alcanza

con un R^2 de 0,630 y un MAPE de 13,3%, mientras que los modelos basados en árboles de decisión quedan considerablemente por debajo. Las Figuras 9, 10, 11 y 12 muestran los gráficos de real vs predicho para cada modelo, siempre acompañados del resultado del Kriging como referencia.




Figura 9: Recuperación en peso real vs predicha: KNN y Kriging.




Figura 10: Recuperación en peso real vs predicha: Gradient Boosting y Kriging.




Figura 11: Recuperación en peso real vs predicha: XGBoost y Kriging.




Figura 12: Recuperación en peso real vs predicha: Random Forest y Kriging.

Para complementar la evaluación, se analizó si los modelos logran respetar el comportamiento espacial de los datos originales. La Figura 13 compara las distribuciones de recuperación en peso estimadas por cada modelo contra la distribución original y la del Kriging. Se observa que KNN es el modelo que mejor reproduce la forma general de la distribución, mientras que los modelos basados en árboles tienden a concentrar sus predicciones en un rango más estrecho, perdiendo representatividad en los extremos.




Figura 13: Comparación de distribuciones de recuperación en peso: datos originales, Kriging y modelos de Machine Learning.

Las Figuras 14, 15 y 16 muestran la deriva espacial de las estimaciones en las tres direcciones principales. En general, todos los modelos logran seguir la tendencia global de los datos originales, aunque con distintos niveles de ajuste. KNN y Kriging son los que más se aproximan a la curva original en las tres direcciones, mientras que los modelos basados en árboles presentan mayor suavizado y pierden algunas variaciones locales, especialmente en la dirección Este.




Figura 14: Deriva espacial en la dirección Este: comparación entre datos originales, Kriging y modelos de Machine Learning.




Figura 15: Deriva espacial en la dirección Norte: comparación entre datos originales, Kriging y modelos de Machine Learning.




Figura 16: Deriva espacial en la dirección Cota: comparación entre datos originales, Kriging y modelos de Machine Learning.

7. Interpretación de resultados

Los resultados obtenidos muestran que el Kriging de la empresa sigue siendo el método más preciso para estimar la recuperación en peso, con un R^2 de 0,796 y un MAPE de 10,5 %. Entre los modelos de Machine Learning, KNN es el que más se acerca con un R^2 de 0,630 y un MAPE de 13,3 %, mientras que los modelos basados en árboles de decisión, Random Forest, Gradient Boosting y XGBoost, quedan todos por debajo de un R^2 de 0,39.

El desempeño de KNN tiene una explicación que vale la pena destacar. El modelo fue configurado con ponderación por distancia (*weights*=“distance”), lo que significa que los vecinos más cercanos tienen mayor influencia en la predicción. Dado que los puntos de validación están en promedio a 6,7 metros de los puntos de entrenamiento, KNN encuentra vecinos muy similares espacialmente, lo que favorece naturalmente su desempeño en este tipo de problema. Es importante aclarar que la validación se realizó sobre coordenadas distintas a las de entrenamiento, por lo que los resultados obtenidos corresponden a una estimación genuinamente externa y no a una memorización de los datos de entrenamiento.

El menor desempeño de los modelos basados en árboles se explica por su naturaleza algorítmica. Estos modelos aprenden particionando el espacio de variables en regiones rectangulares, lo que les dificulta capturar la continuidad espacial gradual que caracteriza a un yacimiento. KNN, al basarse directamente en distancias entre puntos, es estructuralmente más afín a la lógica de la interpolación espacial.

Desde el punto de vista de la coherencia espacial, el análisis de deriva mostró que todos los modelos logran reproducir las tendencias generales del yacimiento en las tres direcciones,

aunque con distintos niveles de ajuste. KNN y Kriging son los que mejor siguen la curva original, mientras que los modelos de árboles presentan mayor suavizado y pierden algunas variaciones locales, especialmente en la dirección Este. En cuanto a la distribución de las estimaciones, KNN es también el modelo que mejor reproduce la forma general de la distribución original, mientras que los modelos de árboles concentran sus predicciones en un rango más estrecho.

En términos prácticos, la brecha de rendimiento entre KNN y el Kriging (R^2 de 0,630 vs 0,796) debe leerse en contexto. El modelo de Kriging fue construido por especialistas con experiencia en el yacimiento, ajustando manualmente parámetros variográficos y dominios de estimación a lo largo de un proceso que puede tomar semanas. El MVP desarrollado en esta tesina, en cambio, es un pipeline automatizado que no requiere ese conocimiento experto ni software especializado, y que entrega resultados en minutos. Considerando esa diferencia en esfuerzo y recursos, un R^2 de 0,630 representa un resultado aceptable y prometedor para una primera versión del sistema.

8. Conclusión

Esta tesina tuvo como objetivo incorporar Machine Learning al flujo de estimación de variables geometalúrgicas, construyendo un MVP en Python que automatice el proceso y permita comparar sus resultados contra el método tradicional utilizado por la empresa. Los resultados muestran que la aproximación es viable, con diferencias de precisión que es importante contextualizar.

Se diseñó un flujo automatizado de preprocesamiento y transformación estadística, se implementó K-Means para la delimitación automática de dominios metalúrgicos espaciales, y se entrenaron y compararon cuatro modelos de aprendizaje supervisado. La validación se realizó de forma externa, contrastando las predicciones de cada modelo contra el modelo de bloques vigente de la empresa sobre los mismos 1.219 puntos de referencia.

El mejor modelo de Machine Learning obtenido, KNN, alcanzó un R^2 de 0,630 frente al 0,796 del Kriging. Esta diferencia se entiende considerando que el modelo de Kriging fue construido con software propietario de alto costo y un proceso de calibración manual que puede tomar semanas, mientras que el pipeline desarrollado entrega una estimación espacial en minutos, sin requerir ese nivel de recursos ni conocimiento experto especializado.

El espíritu de este trabajo es el de introducir la ciencia de datos en la empresa como herramienta para la estimación de recursos. La ciencia de datos aún no forma parte del flujo de trabajo habitual en esta área, y este MVP busca abrir esa puerta. Existe una oportunidad concreta de ganar velocidad, reducir costos y democratizar el análisis de los propios datos sin depender de software externo.

Como trabajo futuro, incorporar variables geológicas o geometalúrgicas adicionales como predictores, explorar modelos diseñados específicamente para datos espaciales, y aplicar técnicas de validación cruzada que respeten la correlación geográfica de los datos, son pasos naturales

para una siguiente versión del MVP. El objetivo de largo plazo es que este tipo de herramientas pueda complementar el flujo de estimación de recursos de la empresa, con el rigor y la transparencia que exige la industria.

Referencias

- [1] Gabriel de Castro Moreira, Rudi César Comiotto Modena, João Felipe Coimbra Leite Costa, and Diego Machado Marques. A workflow for defining geological domains using machine learning and geostatistics. *Tecnologia em Metalurgia, Materiais e Mineração*, 18:e2472, 2021.
- [2] Xavier Emery. Apunte geoestadística. 2007.
- [3] Maximiliano Garnier-Villarreal. Introducción al análisis geoestadístico de datos en geociencias: teoría y aplicación. *Revista Geológica de América Central*, 67:1–22, 6 2022.
- [4] Zhenyi Jia, Shenglu Zhou, Quanlong Su, Haomin Yi, and Junxiao Wang. Comparison study on the estimation of the spatial distribution of regional soilmetal(loid)s pollution based on kriging interpolation and bp neural network. *International Journal of Environmental Research and Public Health*, 15, 1 2018.
- [5] Nadia Mery, Mohammad Maleki, Gabriel País, Andrés Molina, Alejandro Cáceres, and Xavier Emery. Fuzzy classification of mineral resources: Moving toward overlapping categories to account for geological, economic, metallurgical, environmental, and operational criteria. *Natural Resources Research*, 34:1271–1299, 6 2025.
- [6] Glen T. Nwaila, Derek H. Rose, Hartwig E. Frimmel, and Yousef Ghorbani. An integrated geodata science workflow for resource estimation: A case study from the merensky reef, bushveld complex. *Natural Resources Research*, 34:1301–1329, 6 2025.