

Estimación de Variables Geometalúrgicas con Machine Learning

Defensa de Tesina

Ignacio Enrique Rojas Rodríguez

Marzo de 2026

Magíster en Ciencia de Datos para la Innovación
Universidad de Concepción

Profesor guía: Pedro Pinacho | Profesor co-guía: José Ulloa

Agenda

Contexto y problema

Propuesta y objetivos

Datos y depuración

Exploración espacial

Modelado: dominios con K-Means

Modelado: ML vs Kriging

Interpretación de resultados

Conclusiones y trabajo futuro

Contexto y problema

¿Qué es la geometalurgia?

Disciplina que vincula las **características geológicas** de un yacimiento con su **respuesta metalúrgica** en el proceso de beneficio.

El problema central: asimetría de datos

- Datos geológicos → **abundantes** (sondajes extensos)
- Datos geometalúrgicos → **escasos** (ensayos de laboratorio costosos)

Recuperación en peso

Variable objetivo del estudio:

$$R_p(\%) = \frac{Masa_{Conc}}{Masa_{Alim}} \times 100$$

Razón entre la masa del concentrado obtenido y la masa total alimentada.

Kriging — método oficial

- Robusto con alta densidad de muestreo
- Con datos escasos requiere:
 - Juicio experto intensivo
 - Supuestos de estacionariedad
 - Modelado variográfico iterativo
- Depende de **software propietario de alto costo**

Hipótesis

Los algoritmos de Machine Learning poseen la flexibilidad para capturar relaciones espaciales complejas **sin** las rígidas restricciones paramétricas de la geoestadística tradicional.

Propuesta y objetivos

MVP en Python

Pipeline automatizado que ejecuta de principio a fin:

- Carga y limpieza de datos
- Análisis exploratorio (EDA)
- Domaining no supervisado
- Entrenamiento de modelos supervisados
- Estimación masiva sobre modelo de bloques

Tres dimensiones clave

Técnica — Capturar continuidad espacial con métricas de error competitivas

Negocio — Reducir tiempos y costos de software propietario

Adopción — Código base replicable que democratiza el análisis de datos

Objetivo general

Desarrollar y evaluar un flujo de trabajo basado en ML para la **estimación espacial de variables geometalúrgicas con datos escasos**, contrastando su rendimiento frente a las metodologías geoestadísticas tradicionales.

Objetivos específicos

1. Diseñar un flujo automatizado de preprocesamiento y transformación estadística
2. Implementar K-Means para la delimitación de dominios geometalúrgicos espaciales
3. Entrenar y optimizar modelos supervisados para predecir la recuperación en peso
4. Comparar desempeño cuantitativo y coherencia espacial del ML vs Kriging

Datos y depuración

Base de laboratorio

- 1.219 registros válidos de ensayos geometalúrgicos
- Variables: coordenadas 3D (Este, Norte, Cota) + recuperación en peso (%)
- Fuente externa — datos confidenciales

Modelo de bloques (benchmark)

- 343.732 puntos estimados mediante **Kriging**
- Construido con la misma base de laboratorio
- Rol exclusivo: **validación externa** del MVP



Limpieza de datos

- 1.466 registros originales
 - – 230 con valor **-99**
 - – 17 fuera del área de interés
- = **1.219 registros válidos**
(83,2%)

Normal Score Transformation

Ajusta la distribución original a normal estándar ($\mu = 0, \sigma = 1$).


Todo el modelado se realizó sobre la **variable transformada**.



Exploración espacial

Distribución espacial de la recuperación en peso


Distribución Espacial de la Recuperación en Peso (%)



Observaciones clave

- La mayoría de las muestras presenta recuperaciones **inferiores al 21%** (tonos azules)
- Valores altos aparecen de forma **localizada** — no distribuidos aleatoriamente
- Esto confirma **continuidad espacial** y justifica el uso de coordenadas como predictores

Deriva espacial — tendencias macroscópicas



Tendencias observadas

Norte — Caída progresiva desde ~28% (sur) hasta ~15% (norte)

Este — Variaciones moderadas con peak en 8.600 m


Cota — Comportamiento relativamente estable

La posición espacial es una variable predictora relevante.

Modelado: dominios con K-Means

Segmentación espacial con K-Means

Distribución Espacial de la Recuperación en Peso (%)



Configuración


Variables de entrada: coordenadas 3D
+ recuperación en peso transformada

3 clusters — coincide con la segmentación del modelo de la empresa

Cluster	N	Media (%)
1	580	18,74
2	371	19,56
3	268	14,25

Cluster 3 claramente diferenciado con menor recuperación y variabilidad.

Comportamiento metalúrgico por cluster



Interpretación

Cluster 2 presenta el mayor efecto proporcional ($\sim 40\%$): valores altos van acompañados de mayor variabilidad


Cluster 3 es el más homogéneo: recuperación baja y estable

Los tres grupos ocupan **sectores distintos del yacimiento**, validando la coherencia espacial de la segmentación.


Modelado: ML vs Kriging

Cuatro modelos entrenados con el **100% de los datos**,
validados externamente contra el modelo
de bloques Kriging.

Modelo	R ²	RMSE	MAPE
Kriging	0,796	2,992	10,5%
KNN	0,630	4,032	13,3%
Gradient Boost.	0,387	5,187	19,6%
XGBoost	0,364	5,282	20,0%
Random Forest	0,342	5,372	20,3%



Comparación de distribuciones




Hallazgos

KNN reproduce mejor la forma general de la distribución original

Modelos de árboles concentran sus predicciones en un rango más estrecho — pierden representatividad en los extremos

Kriging y KNN son los modelos con mejor **fidelidad distribucional**



Todos los modelos reproducen la tendencia global Norte-Sur

KNN y Kriging siguen más de cerca la curva original en las 3 direcciones

Modelos de árboles presentan mayor suavizado y pierden variaciones locales, especialmente en dirección Este

Interpretación de resultados

¿Por qué KNN es el mejor modelo ML?

Ventaja estructural de KNN

Configurado con

weights="distance":

los vecinos más cercanos tienen mayor influencia en la predicción.

Distancia promedio entre puntos de validación y entrenamiento:

≈ 6,7 metros

KNN es **estructuralmente afín** a la lógica de interpolación espacial.

¿Por qué fallan los árboles?

Random Forest, Gradient Boosting y XGBoost aprenden particionando el espacio en **regiones rectangulares**.

Esto les dificulta capturar la **continuidad espacial gradual** que caracteriza a un yacimiento.

Kriging de la empresa

- Construido por especialistas con experiencia en el yacimiento
- Parámetros variográficos ajustados manualmente
- Proceso que puede tomar **semanas**
- Requiere **software propietario de alto costo**

MVP desarrollado en esta tesina

- Pipeline automatizado en Python
- Sin conocimiento experto especializado
- Resultados en **minutos**
- **Código abierto**, sin licencias

Conclusión

Un R^2 de **0,630** frente al **0,796** del Kriging es un resultado **aceptable y prometedor** considerando la diferencia en esfuerzo y recursos.

Conclusiones y trabajo futuro

Resultados principales

- La aproximación con ML es **viable**
- KNN alcanzó $R^2 = 0,630$ vs $0,796$ del Kriging
- K-Means generó dominios con **coherencia espacial y metalúrgica**
- Todos los modelos reproducen las **tendencias espaciales globales**
- El MVP entrega estimaciones en **minutos**, sin software propietario

Trabajo futuro

1. Incorporar variables geológicas y geometalúrgicas adicionales como predictores
2. Explorar modelos diseñados específicamente para datos espaciales
3. Aplicar validación cruzada que respete la correlación geográfica
4. Integrar el pipeline al flujo oficial de estimación de recursos

¿Preguntas?

Ignacio Enrique Rojas Rodríguez

Magíster en Ciencia de Datos para la Innovación

Universidad de Concepción — Marzo 2026